Politechnika Warszawska
Cyberbezpieczeństwo

WSI

Zadanie 5

Perceptron wielowarstowy

Łukasz Borowski 331159
Bartosz Czerwiński 331165

20 maja 2025

1. Wstęp

Ćwiczenie polegało na implementacji perceptronu wielowarstowego oraz dowolnego algorytmu optymalizacji gradientowej, przy użyciu metody propagacji wstecznej.

2. Opis implementacji

W pliku `MLP.py` zaimplementowano perceptron używający metody stochastycznego spadku gradientowego z mini-batchami, klasycznym sigmoidem i dowolna liczbą warstw ukrytych i neuronów w tych warstwach. Do testów użyto dwóch warstw, z 32 i 16 neuronami w pierwszej i drugiej warstwie. Funkcja kosztu była obliczana przy użyciu metody cross-entropy.

3. Ulepszona wersja

3.1. Regularyzacja L2

Regularyzacja L2 polega na zwiększeniu funkcji kosztu na podstawie wag, pozwala to wyelimonować duże wagi, co zapobiega przetrenowaniu. Zmiana została zaimplementowana w funkcji `compute_cost`.

```
def compute_cost(self, AL, Y):

        m = Y.shape[1]
        # dodaj epsilon dla stabilnosci
        eps = 1e-8
        cost = -np.sum(Y * np.log(AL + eps)) / m
        return cost
```

Kod 1. Funkcja compute_cost w zwykłym modelu

```
def compute_cost(self, AL, Y, lambd=0.01):

        m = Y.shape[1]
        eps = 1e-8
        cross_entropy = -np.sum(Y * np.log(AL + eps)) / m
        # Regularyzacja L2 dla wszystkich wag
        L2_cost = 0
        for l in range(1, self.L + 1):
            L2_cost += np.sum(self.W[l] ** 2)
        L2_cost = (lambd / (2 * m)) * L2_cost
        return cross_entropy + L2_cost
```

Kod 2. Rozszerzona funkcja compute_cost

Jak widać, do kosztu związanego z entropią została dodana suma kwadratów wag, pomnożona przez czynnik $\frac{\lambda}{2m}$, gdzie λ to hiperparametr modelu.

3.2. Dropout

Dropout, czyli losowe odrzucanie neuronów w celu zapobiegnięcia przeuczeniu, zaimplementowano w funkcji `forward`.

```
def forward(self, X):

        cache = {'A0': X}
        A = X
        # warstwy ukryte: sigmoid
        for l in range(1, self.L):
            Z = self.W[l] @ A + self.b[l]
            A = self.sigmoid(Z)
            cache[f'Z{l}'], cache[f'A{l}'] = Z, A
        # warstwa wyjsciowa: softmax
        ZL = self.W[self.L] @ A + self.b[self.L]
        AL = self.softmax(ZL)
        cache[f'Z{self.L}'], cache[f'A{self.L}'] = ZL, AL
        return AL, cache
```

Kod 3. Funkcja forward w zwykłym modelu

```
def forward(self, X, is_training=True, keep_prob=0.8):

        cache = {'A0': X}
        A = X
        # Warstwy ukryte: sigmoid + dropout
        for l in range(1, self.L):
            Z = self.W[l] @ A + self.b[l]
            A = self.sigmoid(Z)
            if is_training:
                D = np.random.rand(*A.shape) < keep_prob
                A *= D / keep_prob  # Skalowanie dla zachowania oczekiwanej wartosci
                cache[f'D{l}'] = D
            cache[f'Z{l}'], cache[f'A{l}'] = Z, A
        # Warstwa wyjsciowa: softmax (bez dropoutu)
        ZL = self.W[self.L] @ A + self.b[self.L]
        AL = self.softmax(ZL)
        cache[f'Z{self.L}'], cache[f'A{self.L}'] = ZL, AL
        return AL, cache
```

Kod 4. Rozszerzona funkcja forward

Do funkcji `forward` przy trenowaniu sieci dodano losowe wybranie zbioru neuronów D będącego podzbiorem pierwotnego zbioru neuronów A, z prawdopodobieństwem wyboru określonym jako hiperparametr modelu. Funkcja kosztu zostaje wtedy przeskalowana dla zachowania oczekiwanej wartości.

4. Testy

Dane zostały podzielone na 3 grupy: treningowe, walidacyjne, testowe w stosunku 60:20:20. 5 razy losowo podzielono dane na 3 zbiory i wykonano na nich uczenie perceptronu, a następnie sprawdzono dokładność na danych testowych. Osiągnięto następujące wyniki:

- Dokładność zwykłego perceptronu: 64.22%
- Dokładność perceptrony z mechanizmami dropoutu oraz regularyzacji: 66.18%

Poniżej znajdują się także wykresy kosztu dla danych walidacyjnych i treningowych w kolejnych epokach dla obu perceptronów:

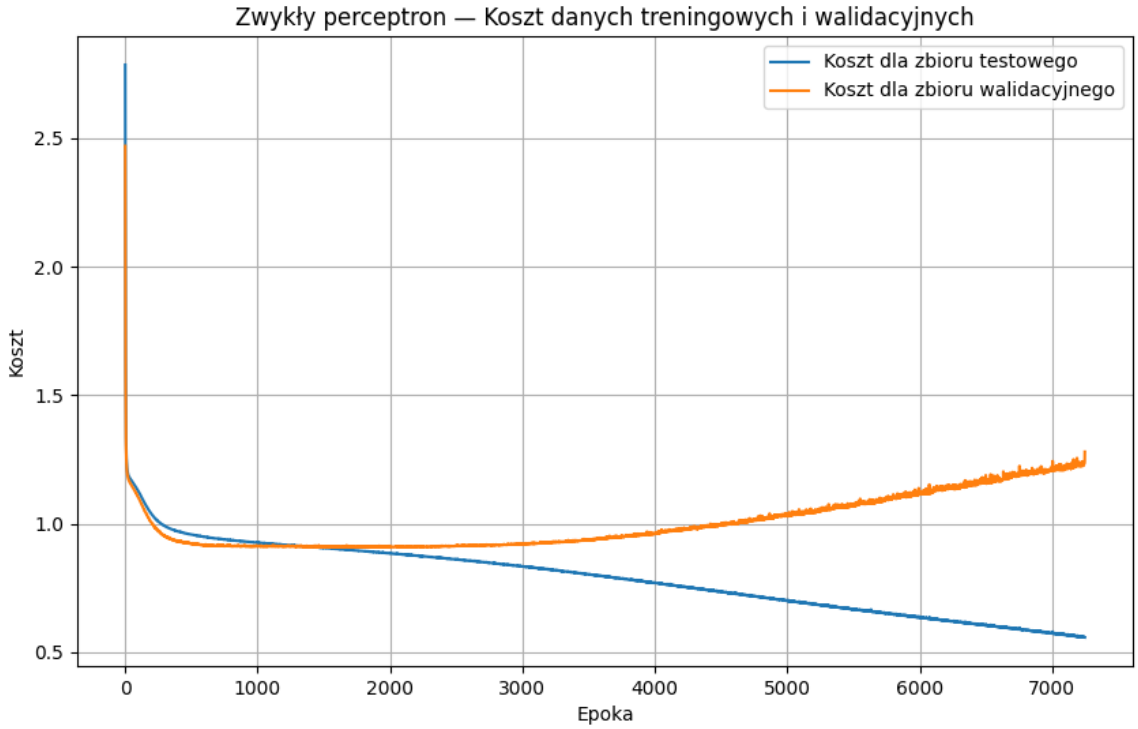

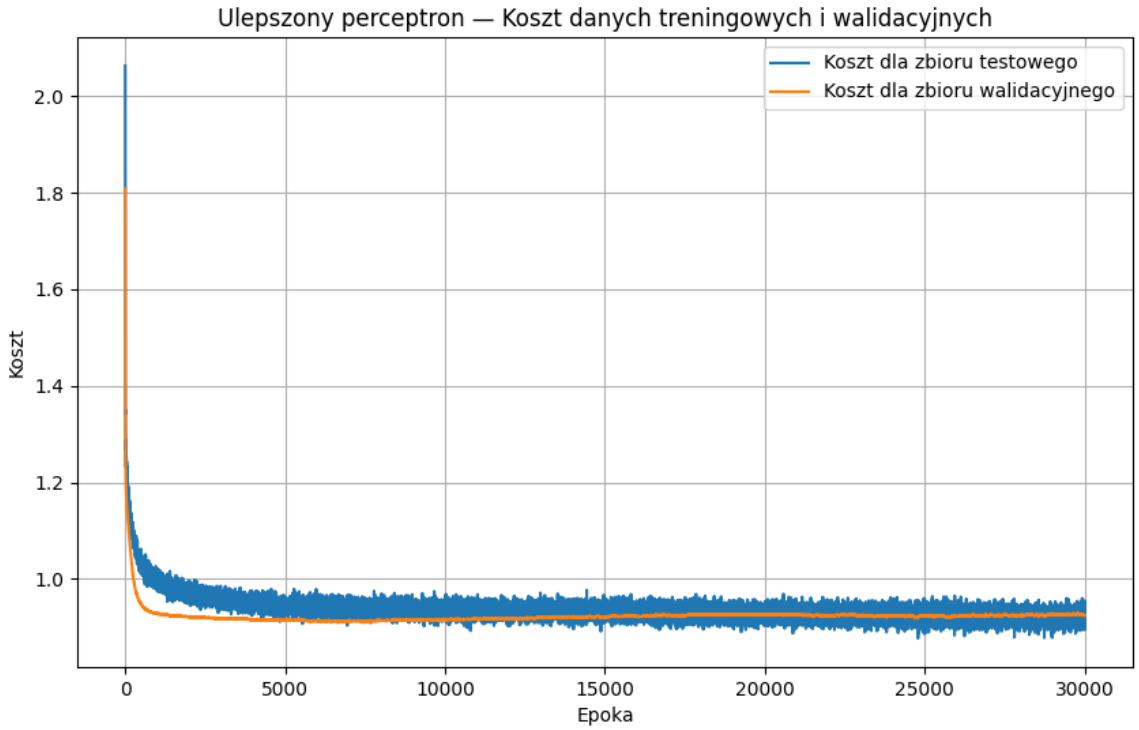

5. Opis wyników

Wykorzystanie bardziej zaawansowanego perceptronu daje lepszą dokładność jednak model ten uczy się wolniej i potrzebuje więcej iteracji w celu uzyskania zadowalających wyników.

Na wykresach można zauważyć, że dla zwykłego perceptronu dochodzi do przeuczenia już po niecałych 1000 epokach, natomiast perceptron wykorzystujący regularyzację oraz dropout jest znacznie bardziej odporny na przeuczanie.